

# CLASIFICACION CON SVM Y NN

En la presente actividad se va a emplear un dataset que contiene información de características de celulares para clasificarlos en un rango de precios.

La información del *dataset* es:

- *battery\_power*: Energía total que una batería puede almacenar en un tiempo medido en *mAh*
  - *blue*: Indica si tiene *bluetooth* o no
  - *clock\_speed*: Velocidad del microprocesador
  - *dual\_sim*: Indica si tiene soporte dual de *sim* o no
  - *fc*: Megapíxeles de la cámara frontal
  - *four\_g*: Indica si tiene 4G o no
  - *int\_memory*: Memoria interna en GB
  - *m\_dep*: Grosor del celular en cm
  - *mobile\_wt*: Peso del celular
  - *n\_cores*: Número de núcleos del procesador
  - *pc*: Megapíxeles de la cámara principal
  - *px\_height*: Alto de la resolución de píxeles
  - *px\_width*: Ancho de resolución de píxeles
  - *ram*: RAM en MB
  - *sc\_h*: Alto de la pantalla en cm
  - *sc\_w*: Ancho de la pantalla en cm
  - *talk\_time*: tiempo máximo que durará una sola carga de la batería
  - *tres\_g*: Indica si es 3G o no
  - *touch\_screen*: Indica si tiene pantalla táctil o no
  - *wifi*: Indica si tiene wifi o no
  - ***price\_range***: Es la variable objetivo con valor 0 (bajo costo), 1 (costo medio), 2 (costo alto) y 3 (costo muy alto).
- 

## Recomendaciones generales

1. **Establece una semilla aleatoria** para garantizar la reproducibilidad de los resultados (la semilla se definirá más adelante).
2. **Lee el dataset solo una vez**, al inicio del notebook. Evita cargarlo repetidamente.
3. **Usa exclusivamente los hiperparámetros indicados** en cada modelo. Por ejemplo, en el primer SVM utiliza C=1. No modifiques ningún valor a menos que se solicite explícitamente.
4. **Organiza tu notebook** incluyendo celdas para: código, visualizaciones y análisis textual (explicaciones, interpretaciones, etc.).

5. **Responde de manera clara y completa**, siguiendo las instrucciones de cada ejercicio. Cuida tu redacción, ortografía y coherencia.
6. **Ante dudas o ambigüedades**, consulta a través de los canales de comunicación establecidos para resolverlas oportunamente.
7. **Antes de entregar tu actividad**, reinicia el kernel y ejecuta todas las celdas nuevamente para verificar la coherencia de los resultados.

## IMPORTACIÓN DE LIBRERIAS A UTILIZAR

```
import numpy as np
import pandas as pd

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split, GridSearchCV

from sklearn.svm import SVC
from sklearn.neural_network import MLPClassifier

from sklearn.metrics import accuracy_score, confusion_matrix,
classification_report
```

## Definición de semilla

*# La semilla que se va a emplear en la presente actividad es 1234, la cual no debes modificar, para garantizar que los resultados que reportes coincidan con los esperados*

```
seed = 1234
```

## CARGA DEL DATASET

```
data = pd.read_csv('train.csv')
data
```

	battery_power	blue	clock_speed	dual_sim	fc	four_g
int_memory	\					
0	842	0	2.2	0	1	0
7						
1	1021	1	0.5	1	0	1
53						
2	563	1	0.5	1	2	1
41						
3	615	1	2.5	0	0	0
10						
4	1821	1	1.2	0	13	1
44						
...	...	...	...	...	...	...

..	1995	794	1	0.5	1	0	1		
2	1996	1965	1	2.6	1	0	0		
39	1997	1911	0	0.9	1	1	1		
36	1998	1512	0	0.9	0	4	1		
46	1999	510	1	2.0	1	5	1		
45									
sc_w	m_dep	mobile_wt	n_cores	...	px_height	px_width	ram	sc_h	
0	0.6	188	2	...	20	756	2549	9	
7	0.7	136	3	...	905	1988	2631	17	
1	0.9	145	5	...	1263	1716	2603	11	
3	0.8	131	6	...	1216	1786	2769	16	
2	0.6	141	2	...	1208	1212	1411	8	
2	...	...	...	...	...	...	...	...	
...	...	...	...	...	...	...	...	...	
4	0.8	106	6	...	1222	1890	668	13	
4	1996	0.2	187	4	...	915	1965	2032	11
10	1997	0.7	108	8	...	868	1632	3057	9
1	1998	0.1	145	5	...	336	670	869	18
10	1999	0.9	168	6	...	483	754	3919	19
4									
	talk_time	three_g	touch_screen	wifi	price_range				
0	19	0	0	1	1				
1	7	1	1	0	2				
2	9	1	1	0	2				
3	11	1	0	0	2				
4	15	1	1	0	1				
...	...	...	...	...	...				
1995	19	1	1	0	0				
1996	16	1	1	1	2				
1997	5	1	1	0	3				
1998	19	1	1	1	0				
1999	2	1	1	1	3				

```
[2000 rows x 21 columns]

#Tamaño del dataset
data.shape

(2000, 21)

#Información de las variables
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 21 columns):
 #   Column            Non-Null Count  Dtype  
--- 
 0   battery_power    2000 non-null   int64  
 1   blue              2000 non-null   int64  
 2   clock_speed      2000 non-null   float64 
 3   dual_sim          2000 non-null   int64  
 4   fc                2000 non-null   int64  
 5   four_g            2000 non-null   int64  
 6   int_memory        2000 non-null   int64  
 7   m_dep             2000 non-null   float64 
 8   mobile_wt         2000 non-null   int64  
 9   n_cores           2000 non-null   int64  
 10  pc                2000 non-null   int64  
 11  px_height         2000 non-null   int64  
 12  px_width          2000 non-null   int64  
 13  ram               2000 non-null   int64  
 14  sc_h              2000 non-null   int64  
 15  sc_w              2000 non-null   int64  
 16  talk_time         2000 non-null   int64  
 17  three_g           2000 non-null   int64  
 18  touch_screen      2000 non-null   int64  
 19  wifi              2000 non-null   int64  
 20  price_range       2000 non-null   int64  
dtypes: float64(2), int64(19)
memory usage: 328.3 KB
```

## 1. Análisis Exploratorio de Datos (EDA)

### Variables numéricas

```
#Resumen estadístico de las variables
data.describe().transpose()
```

	count	mean	std	min	25%	50%
\battery_power	2000.0	1238.51850	439.418206	501.0	851.75	1226.0
blue	2000.0	0.49500	0.500100	0.0	0.00	0.0
clock_speed	2000.0	1.52225	0.816004	0.5	0.70	1.5
dual_sim	2000.0	0.50950	0.500035	0.0	0.00	1.0
fc	2000.0	4.30950	4.341444	0.0	1.00	3.0
four_g	2000.0	0.52150	0.499662	0.0	0.00	1.0
int_memory	2000.0	32.04650	18.145715	2.0	16.00	32.0
m_dep	2000.0	0.50175	0.288416	0.1	0.20	0.5
mobile_wt	2000.0	140.24900	35.399655	80.0	109.00	141.0
n_cores	2000.0	4.52050	2.287837	1.0	3.00	4.0
pc	2000.0	9.91650	6.064315	0.0	5.00	10.0
px_height	2000.0	645.10800	443.780811	0.0	282.75	564.0
px_width	2000.0	1251.51550	432.199447	500.0	874.75	1247.0
ram	2000.0	2124.21300	1084.732044	256.0	1207.50	2146.5
sc_h	2000.0	12.30650	4.213245	5.0	9.00	12.0
sc_w	2000.0	5.76700	4.356398	0.0	2.00	5.0
talk_time	2000.0	11.01100	5.463955	2.0	6.00	11.0
three_g	2000.0	0.76150	0.426273	0.0	1.00	1.0
touch_screen	2000.0	0.50300	0.500116	0.0	0.00	1.0
wifi	2000.0	0.50700	0.500076	0.0	0.00	1.0
price_range	2000.0	1.50000	1.118314	0.0	0.75	1.5
		75%	max			
battery_power	1615.25	1998.0				
blue	1.00	1.0				
clock_speed	2.20	3.0				
dual_sim	1.00	1.0				
fc	7.00	19.0				
four_g	1.00	1.0				

int_memory	48.00	64.0
m_dep	0.80	1.0
mobile_wt	170.00	200.0
n_cores	7.00	8.0
pc	15.00	20.0
px_height	947.25	1960.0
px_width	1633.00	1998.0
ram	3064.50	3998.0
sc_h	16.00	19.0
sc_w	9.00	18.0
talk_time	16.00	20.0
three_g	1.00	1.0
touch_screen	1.00	1.0
wifi	1.00	1.0
price_range	2.25	3.0

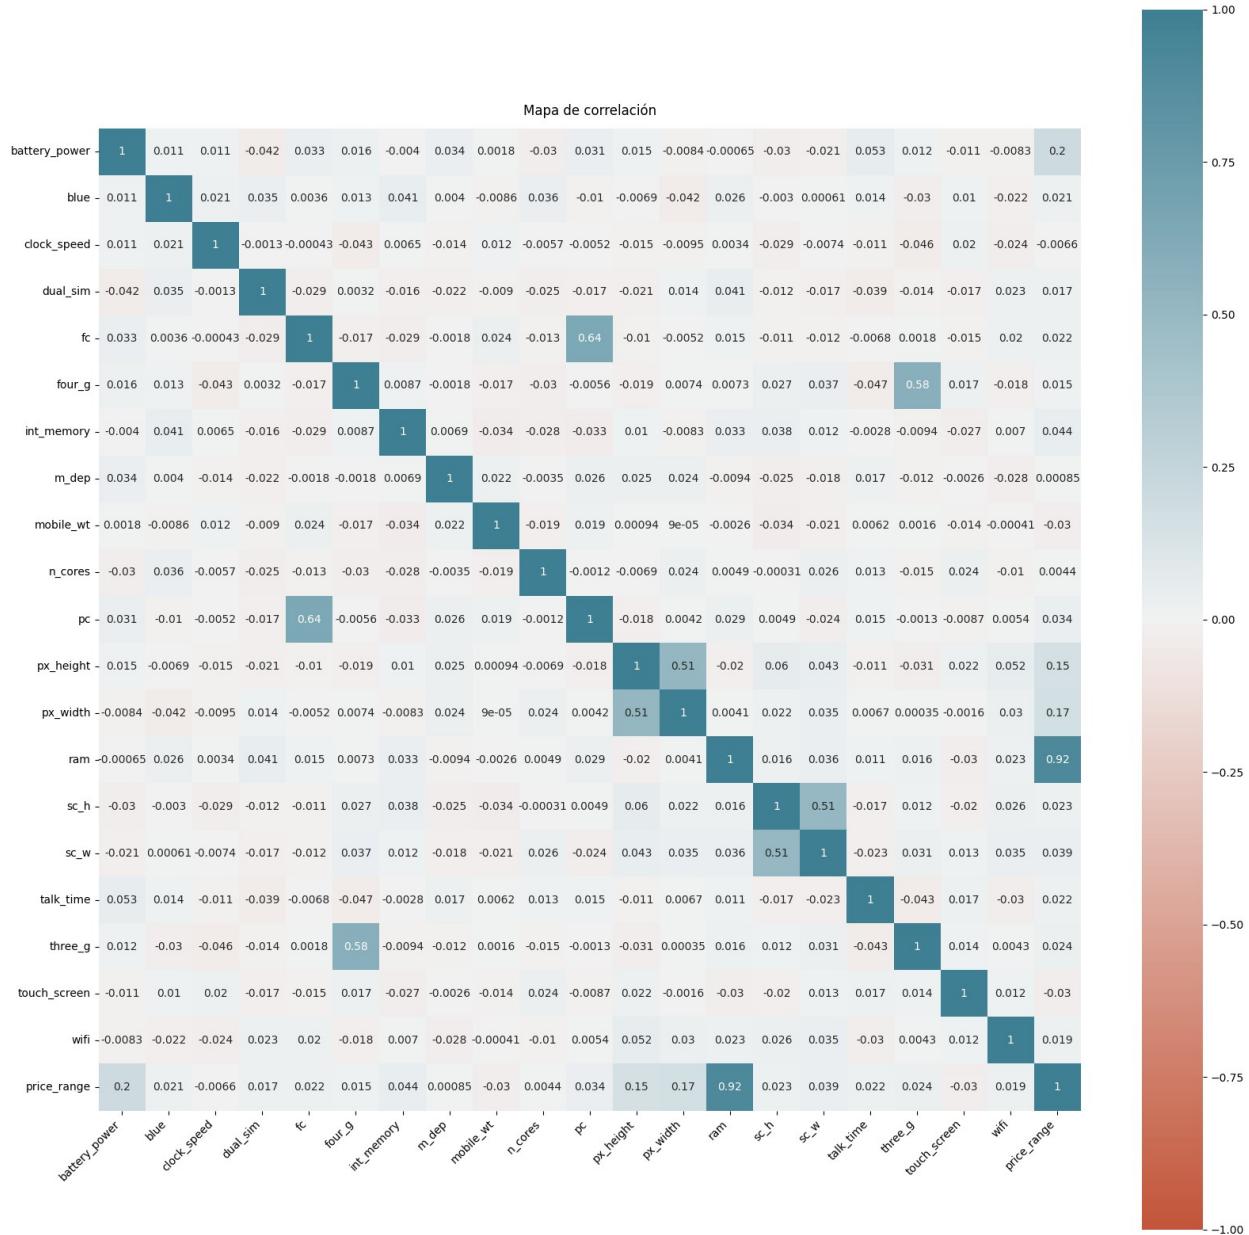
### 1.1. Escriba el código que permita crear la matriz de correlación de todas las variables numéricas:

```
corr = data.corr()

fix, ax = plt.subplots(figsize=(20,20))

ax = sns.heatmap(
    corr,
    vmin=-1, vmax=1, center=0,
    cmap=sns.diverging_palette(20, 220, n=200, as_cmap=True),
    square=True,
    annot=True
)
ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=45,
    horizontalalignment='right'
);
ax.set_title('Mapa de correlación', fontdict={'fontsize':12}, pad=12);

plt.show()
```



## Variables categóricas

### 1.2. Escriba el código para su análisis y la creación de gráficos de frecuencia:

```
candidatas = ['blue', 'dual_sim', 'four_g', 'three_g', 'touch_screen', 'wifi', 'n_cores', 'price_range']

cat_cols = [c for c in candidatas if c in data.columns]

if not cat_cols:
    cat_cols = [col for col in data.columns if data[col].nunique() <=
```

```

5 and pd.api.types.is_integer_dtype(data[col])]

for col in cat_cols:
    print(f'== {col} ==')
    vc = data[col].value_counts().sort_index()
    pct =
data[col].value_counts(normalize=True).sort_index().mul(100).round(2)
    freq_df = pd.DataFrame({'count': vc, 'percent(%)': pct})
    display(freq_df)
    print()

n = len(cat_cols)
if n:
    cols = 3
    rows = (n + cols - 1) // cols
    fig, axs = plt.subplots(rows, cols, figsize=(6*cols, 4*rows))
    axs = axs.flatten()
    total = len(data)
    for i, col in enumerate(cat_cols):
        ax = axs[i]
        sns.countplot(x=col, data=data, ax=ax, palette='pastel',
hue=col, legend=False)
        # Quitar leyenda si quedó presente en algunas versiones
        if ax.get_legend() is not None:
            ax.get_legend().remove()
        ax.set_title(f'{col} - Frecuencias (n={total})')
        counts = data[col].value_counts().sort_index()
        # Anotar conteos y porcentajes encima de las barras
        for j, val in enumerate(counts.index):
            cnt = counts.loc[val]
            pct = cnt / total * 100
            ax.text(j, cnt + total*0.01, f'{cnt} ({pct:.1f}%)',
ha='center', fontsize=10)
            ax.set_xlabel('')
        # eliminar ejes sobrantes
        for k in range(i+1, len(axs)):
            fig.delaxes(axs[k])
    plt.tight_layout()
    plt.show()

== blue ==
      count  percent(%)
blue
0      1010      50.5
1       990      49.5

== dual_sim ==

```

```
          count  percent(%)
dual_sim
0           981      49.05
1          1019      50.95

== four_g ==
          count  percent(%)
four_g
0           957      47.85
1          1043      52.15

== three_g ==
          count  percent(%)
three_g
0           477      23.85
1          1523      76.15

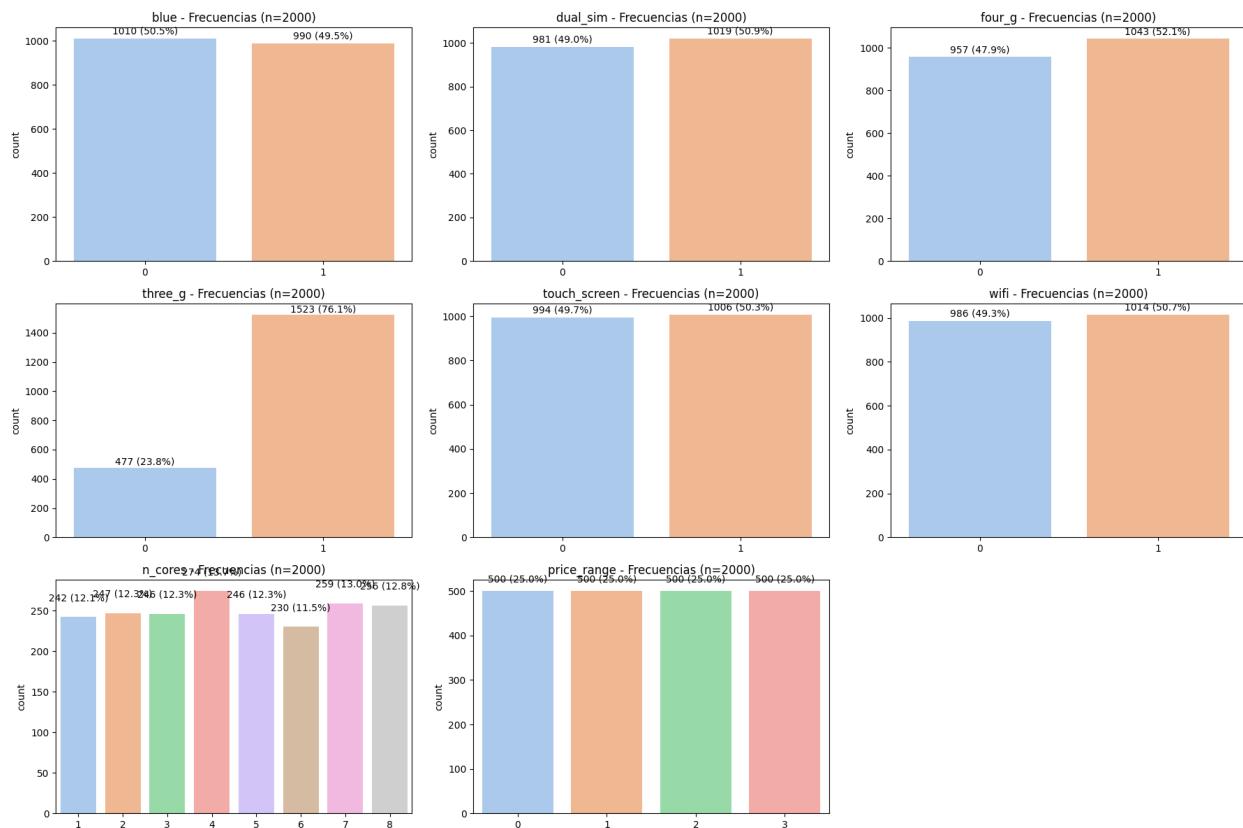
== touch_screen ==
          count  percent(%)
touch_screen
0           994      49.7
1          1006      50.3

== wifi ==
          count  percent(%)
wifi
0           986      49.3
1          1014      50.7

== n_cores ==
          count  percent(%)
n_cores
1           242      12.10
2           247      12.35
3           246      12.30
4           274      13.70
5           246      12.30
6           230      11.50
7           259      12.95
8           256      12.80
```

```
== price_range ==

      count percent(%)
price_range
0          500    25.0
1          500    25.0
2          500    25.0
3          500    25.0
```



### 1.3. Escriba el código que permita validar si el dataset está balanceado

```
print(data['price_range'].value_counts())

price_range
1    500
2    500
3    500
0    500
Name: count, dtype: int64
```

## PREPROCESAMIENTO DE DATOS

```
#Crear una copia del dataset para modificaciones
data2 = data.copy()

#Verificar tamaño
data2.shape

(2000, 21)

# Separación de los datos en train y test
X = data2.drop(columns = 'price_range')
y = data2['price_range']

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    train_size = 0.8,
    random_state = seed,
    shuffle = True
)
```

Escriba el código que permita reescalar todos los atributos del dataset utilizando la función del StandardScaler:

```
# Código para reescalar X_train y X_test mediante StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

## 2. Aplicación de SVM sobre los datos

⚠ Importante:

A partir de esta sección, utiliza los datos estandarizados.

### 2.1. Escriba el código que permita crear un modelo utilizando SVM con kernel lineal, el valor de C =1 y random\_state=seed

```
# Creación del modelo SVM lineal
modeloSVM = SVC(C=1, kernel='linear', random_state=seed)
modeloSVM.fit(X_train_scaled, y_train)

SVC(C=1, kernel='linear', random_state=1234)

# Predicciones test
predictSVM = modeloSVM.predict(X_test_scaled)
predictSVM
```

```
array([1, 2, 2, 2, 2, 2, 1, 3, 1, 3, 3, 3, 0, 2, 3, 0, 3, 2, 2, 2, 0,
1,
     1, 0, 3, 2, 0, 3, 1, 0, 2, 0, 3, 3, 3, 3, 3, 3, 3, 0, 2, 3, 1, 3,
2,
     1, 0, 2, 2, 0, 3, 3, 0, 1, 2, 1, 3, 3, 1, 2, 1, 1, 2, 2, 1, 2,
1,
     0, 3, 3, 3, 0, 3, 1, 3, 1, 2, 1, 2, 2, 3, 3, 2, 1, 0, 2, 3, 2,
3,
     3, 1, 1, 2, 0, 1, 3, 0, 1, 2, 2, 2, 0, 1, 0, 2, 3, 2, 3, 3, 1,
1,
     2, 2, 0, 1, 2, 3, 3, 2, 2, 1, 1, 0, 1, 2, 3, 1, 2, 1, 1, 0, 1,
1,
     0, 0, 0, 1, 3, 1, 2, 0, 3, 3, 1, 1, 3, 0, 2, 0, 2, 0, 0, 3, 0,
3,
     1, 3, 2, 2, 1, 2, 2, 3, 0, 2, 2, 1, 1, 2, 0, 0, 1, 3, 1, 1, 3,
1,
     3, 0, 2, 2, 3, 1, 1, 0, 0, 0, 1, 1, 0, 1, 0, 0, 0, 2, 2, 0, 1,
0,
     1, 1, 2, 3, 3, 0, 2, 1, 3, 3, 1, 3, 1, 0, 3, 1, 2, 3, 3, 2, 3,
3,
     3, 2, 0, 3, 0, 3, 1, 0, 2, 3, 0, 0, 2, 1, 3, 1, 3, 1, 1, 1, 3,
1,
     2, 0, 2, 2, 3, 2, 3, 1, 1, 3, 1, 3, 2, 0, 2, 1, 0, 2, 3, 1, 0,
0,
     0, 0, 1, 3, 2, 2, 1, 0, 3, 0, 0, 2, 3, 0, 3, 2, 1, 1, 3, 0, 0,
2,
     0, 0, 0, 1, 0, 2, 2, 1, 2, 0, 0, 0, 0, 3, 3, 2, 0, 0, 3, 1, 3,
2,
     0, 0, 1, 2, 3, 3, 2, 3, 3, 2, 1, 1, 3, 2, 1, 3, 3, 2, 2, 0, 3,
1,
     0, 2, 1, 3, 0, 0, 2, 1, 1, 0, 2, 3, 3, 1, 3, 1, 0, 3, 3, 1, 2,
1,
     3, 1, 0, 0, 3, 1, 0, 2, 3, 2, 3, 0, 1, 2, 3, 2, 3, 2, 2, 1, 0,
1,
     3, 2, 3, 1, 1, 2, 3, 0, 0, 3, 0, 1, 3, 0, 1, 1, 3, 0, 2, 3, 3,
0,
     1, 0, 3, 0])
```

## 2.2. Escriba el código que permita hallar la exactitud (accuracy) del modelo SVM anteriormente entrenado:

```
accuracy = accuracy_score(y_test, predictSVM)
print("Exactitud del modelo SVM:", accuracy)
```

Exactitud del modelo SVM: 0.9675

## 2.3. Escriba el código que permita encontrar los mejores parámetros para el modelo SVM, con un param\_grid = {'C': np.linspace(0.1, 100, 20), 'kernel': ('linear', 'rbf')}

Ajuste de hiperparámetros (GridSearchCV)

⚠ Restricción:

**No imprimas los resultados del GridSearchCV.** Solo utiliza los mejores parámetros encontrados.

```
# Parametros y los valores que van a tomar
param_grid = {
    'C': np.linspace(0.1, 100, 20),
    'kernel': ['rbf', 'linear']
}

grid = GridSearchCV(SVC(), param_grid, refit = True, verbose = 0)

# Para que no se impriman los resultados, estos se asignan a _
_ = grid.fit(X_train_scaled, y_train)

# Se asignan los resultados a un dataframe
resultados = pd.DataFrame(grid.cv_results_)
resultados.filter(regex = '(param.*|mean_t|std_t)')\
    .drop(columns = 'params')\
    .sort_values('mean_test_score', ascending = False) \
    .head(5)

      param_C  param_kernel  mean_test_score  std_test_score
19  47.421053      linear        0.969375     0.012087
17  42.163158      linear        0.969375     0.011075
15  36.905263      linear        0.969375     0.008705
25  63.194737      linear        0.968750     0.010270
11  26.389474      linear        0.968750     0.010643
```

## 2.4. Escriba el código que permita conocer los mejores parámetros encontrados en el ítem anterior

```
# print best parameter after tuning
print(f'Mejores hiperparámetros {grid.best_params_}')

Mejores hiperparámetros {'C': np.float64(36.905263157894744),
'kernel': 'linear'}
```

## 2.5. Escriba el código que permita hallar la exactitud del modelo de SVM aplicando los mejores parámetros

```
# Accuracy de test del modelo  
#  
=====  
=====  
accuracy = grid.best_score_  
print(f'Accuracy del modelo SVM optimizado: {accuracy}')  
  
Accuracy del modelo SVM optimizado: 0.969375
```

## 2.6. Escriba el código que permita hallar las métricas del modelo entrenado en el ítem anterior. Utilice la función classification\_report

```
class_label = np.unique(predictSVM).astype(str).tolist()  
print('Reporte de métricas del modelo SVM optimizado: ')  
print(classification_report(y_test, predictSVM,  
target_names=class_label))  
  
Reporte de métricas del modelo SVM optimizado:  
precision recall f1-score support  
  
          0       0.98      0.99      0.98      93  
          1       0.96      0.95      0.96     102  
          2       0.96      0.94      0.95      98  
          3       0.97      0.99      0.98     107  
  
accuracy           0.97      0.97      0.97     400  
macro avg         0.97      0.97      0.97     400  
weighted avg      0.97      0.97      0.97     400
```

## 3. REDES NEURONALES

⚠ Recordatorio:

- Mantén los datos normalizados (los mismos que usaste en SVM).
- No regreses al dataset original ni repitas pasos anteriores, a menos que se indique explícitamente.

## 3.1. Escriba el código que permita entrenar un perceptrón multicapa con 3 capas ocultas con 200, 100 y 50 neuronas respectivamente en cada capa. Función de activación 'Relu' y random\_state=seed

```
classifier = MLPClassifier(hidden_layer_sizes=(200, 100, 50),  
                           activation='relu',
```

```

        random_state=seed)
classifier.fit(X_train_scaled, y_train)
y_pred = classifier.predict(X_test_scaled)

```

### 3.2. Escriba el código que permita hallar la exactitud del modelo de redes neuronales anteriormente entrenado:

```

accuracy_nn = accuracy_score(y_test, y_pred)
print(f'Accuracy del modelo de Red Neuronal: {accuracy_nn} ')
Accuracy del modelo de Red Neuronal: 0.925

```

### 3.3. Escriba el código que permita hallar las métricas del modelo entrenado en el ítem anterior. Utilice la función classification\_report

```

print('Reporte de métricas del modelo de Red Neuronal:')
print(classification_report(y_test, y_pred))

Reporte de métricas del modelo de Red Neuronal:
precision    recall    f1-score   support
          0       0.94      0.96      0.95      93
          1       0.93      0.85      0.89     102
          2       0.87      0.94      0.90      98
          3       0.97      0.95      0.96     107

   accuracy                           0.93      400
  macro avg       0.93      0.93      0.92      400
weighted avg       0.93      0.93      0.92      400

```

## 4. Conclusiones

Escribe tus conclusiones finales, reflexionando sobre los resultados obtenidos con SVM y MLP. Compara los siguientes aspectos:

1. Métricas relevantes:

- ¿Cuáles métricas fueron clave para evaluar el desempeño?

Tras la ejecución de los distintos modelos especificados, Support Vector Machine (SVM) y Redes Neuronales (RN), las métricas más relevantes que permiten evaluar la efectividad del modelo y su entrenamiento son:

- Precision
- F1-score

1. Fortalezas y limitaciones:

- Ventajas y desventajas de cada modelo en este caso específico.

Después de ejecutar el código en ambos modelos, se concluye que el modelo SVM ofrece mejores resultados de precisión que el modelo de Redes Neuronales.

## Redes Neuronales

Aunado al coste computacional que conlleva el modelo de RN con subcapas, el proceso iterativo durante su entrenamiento puede llegar a tomar más tiempo, en especial si no se cuenta con un sistema adecuado con el número suficiente de núcleos para realizar el proceso de manera rápida.

Cabe resaltar que el modelo de RN muestra mayor eficacia en problemas complejos, aunque puede llegar a presentar sobreajuste.

## Support Vector Machine

Para las dimensiones del dataset, este modelo presenta una muy buena solución, además de tiempos de entrenamiento y predicción más rápidos, incluso si no se cuenta con sistemas robustos de varios núcleos.

A pesar de mostrar tiempos de entrenamiento adecuados, todo depende del tamaño del dataset y del número de parámetros con los que se trabaja, ya que si se tienen más características, es necesario evitar el sobreentrenamiento, pues puede derivar en un sobreajuste del modelo.