

Analizador de Sentimientos

Dataset IMDb

Universidad Internacional de La Rioja (UNIR)

Master en Inteligencia Artificial

Asignatura: Procesamiento del Lenguaje Natural

Autor: Omar Joel Montemayor Charles /

Fecha: 13 de Abril de 2026

RESUMEN - Actividad 2

Este documento sintetiza los contenidos de la Actividad 2 de PLN, estructurados en tres partes: (I) Marco Teórico, (II) Tutorial HuggingFace + Argilla y (III) Implementación Práctica con clasificadores clásicos de Machine Learning sobre el corpus IMDb de 50 000 reseñas.

INDICE DE CONTENIDOS

1. Parte I - Marco Teorico e Investigacion	3
1.1 Definicion de analisis de sentimientos	3
1.2 Caso de uso: Keerthi, Harish y Darshan (2018)	4
1.3 Retos abiertos en el analisis de sentimientos	5
1.4 Reflexion sobre el papel de los datos	6
2. Parte II - Tutorial HuggingFace + Argilla	7
2.1 Descripcion del flujo de trabajo	7
2.2 Fortalezas y limitaciones	7
2.3 Adaptaciones para modelos clasicos y espanol	8
3. Parte III - Implementacion Practica (ML Clasico)	9
4. Conclusiones	9
5. Referencias	10

PARTE I: MARCO TEORICO E INVESTIGACION

1.1 Definicion de analisis de sentimientos

Que es el analisis de sentimientos?

El analisis de sentimientos -tambien llamado mineria de opiniones- es una subdisciplina del Procesamiento del Lenguaje Natural (PLN) cuyo objetivo es identificar, extraer y cuantificar la informacion afectiva presente en texto libre. A diferencia del analisis de contenido objetivo, trabaja con lenguaje inherentemente subjetivo: opiniones, juicios de valor, expresiones coloquiales e incluso ironia o sarcasmo. Las tareas principales incluyen clasificacion de polaridad (positiva, negativa, neutra), deteccion de emociones basicas (alegria, tristeza, ira) y analisis a nivel de aspecto (ABSA).

Particularidades del dataset IMDb

El dataset IMDb contiene 50 000 resenas de peliculas con etiquetado binario (positivo / negativo) derivado del rating numerico del usuario. Sus caracteristicas mas relevantes son:

- Texto largo: promedio de ~230 palabras por resena, lo que aporta contexto rico pero tambien ruido lexico y mayor coste computacional.
- Vocabulario cinematografico especifico (actores, generos, trama), que puede limitar la generalizacion a otros dominios.
- Balance perfecto de clases: 25 000 positivos / 25 000 negativos, lo que facilita la evaluacion con metricas de exactitud.
- Benchmark estandar en la literatura desde el trabajo seminal de Maas et al. (2011).
- Presencia de lenguaje subjetivo complejo: metáforas, sarcasmo y referencias culturales dificiles de capturar con metodos no profundos.

Particularidades del dataset SST-2

SST-2 (Stanford Sentiment Treebank, version binaria, incluido en el benchmark GLUE) proviene de resenas de Rotten Tomatoes. Se diferencia de IMDb en aspectos clave:

- Oraciones cortas: promedio de ~19 palabras. Las instancias son frases extraidas, no resenas completas.
- Anotacion en arbol sintactico: proporciona etiquetas a nivel de frase y sub-frase, permitiendo estudiar la composicionalidad del sentimiento.
- Benchmark de facto para Transformers: SST-2 fue la tarea de clasificacion de referencia en los primeros papers de BERT y sigue siendo estandar para comparar modelos de lenguaje preentrenados.

Comparativa IMDb vs. SST-2

Mientras IMDb favorece modelos capaces de procesar textos largos con vocabulario especializado, SST-2 evalua la comprension del sentimiento a nivel de frase corta. Los Transformers como BERT superan el 95% de F1 en SST-2, mientras en IMDb los modelos clasicos bien ajustados alcanzan resultados competitivos (aprox. 89%). Ambos datasets son complementarios: IMDb cuantifica la robustez ante texto largo y SST-2 la precision morfica a nivel de subexpresion.

1.2 Caso de uso: Keerthi, Harish y Darshan (2018)

Descripcion del problema

Los autores plantean que los metodos de extraccion de características aisladas (solo TF-IDF o solo características semanticas) presentan limitaciones para capturar la riqueza lexica y semantica de las resenas de cine. Su propuesta central es un enfoque hibrido que combina multiples representaciones para mejorar la clasificacion de sentimiento en el corpus IMDb.

Pipeline propuesto

El flujo de trabajo comprende cuatro etapas fundamentales:

- Preprocesamiento: eliminacion de etiquetas HTML, tokenizacion, minusculas, stopwords y stemming.
- Extraccion de características hibrida: (a) TF-IDF para importancia estadistica de terminos; (b) características estadísticas como bigramas y longitud de resena; (c) características semanticas con SentiWordNet (puntuaciones de positividad / negatividad / objetividad por sinonset).
- Concatenacion de los tres vectores en una representacion unica.
- Evaluacion de cuatro clasificadores: Naive Bayes, SVM (kernel lineal), Regresion Logistica y KNN.

Resultados y conclusiones del articulo

El SVM con el metodo hibrido obtuvo el mejor resultado: 89.2% de exactitud en un subconjunto de 25 000 resenas de IMDb. Las conclusiones mas relevantes son:

- La combinacion de representaciones estadísticas y semanticas mejora consistentemente la exactitud frente al TF-IDF aislado en todos los clasificadores.
- El SVM lineal es el clasificador mas robusto para este dominio, gracias a su capacidad de separacion optima en espacios de alta dimensionalidad.
- Los lexicos de sentimiento como SentiWordNet aportan informacion de polaridad que los vectores de frecuencia no pueden capturar, especialmente para palabras de polaridad fuerte.
- KNN muestra el peor rendimiento relativo por la maldicion de la dimensionalidad inherente a vectores TF-IDF dispersos en miles de dimensiones.

1.3 Retos abiertos en el analisis de sentimientos

A partir de Keerthi et al. (2018) y de la literatura reciente, se identifican seis retos principales que siguen siendo objeto de investigacion activa en PLN:

Deteccion de sarcasmo e ironia

El sarcasmo expresa un sentimiento opuesto al significado literal. Por ejemplo, "Brillante guion, digno de un Oscar" puede ser un insulto. Los modelos clasicos basados en bolsa de palabras o TF-IDF son especialmente vulnerables, ya que el lexico positivo domina la representacion vectorial. Se requieren modelos que capturen el contexto pragmatico, el tono y, en algunos casos, informacion prosodica. Los avances mas recientes combinan señales contextuales de Transformers con grafos de conocimiento para inferir intencion implicita.

Dependencia del dominio (domain adaptation)

Un modelo entrenado en IMDb puede no generalizar a productos electrónicos o noticias financieras, donde las mismas palabras tienen connotaciones diferentes. La mayoría de los sistemas comerciales necesita anotación específica del dominio de destino, lo cual supone un coste significativo. Los enfoques de transferencia de dominio y adaptación continua (continual learning) buscan mitigar este problema sin reentrenamiento completo.

Idiomas de bajos recursos (low-resource languages)

La gran mayoría de los datasets etiquetados están en inglés. Para lenguas con pocos recursos (quechua, idiomas africanos, lenguas regionales), los modelos preentrenados y los métodos clásicos tienen un rendimiento muy inferior. La traducción automática puede introducir errores que distorsionan el sentimiento. Modelos multilingües como XLM-RoBERTa ofrecen una alternativa parcial, aunque con un gap de rendimiento frente a los modelos monolingües.

Análisis de sentimiento a nivel de aspecto (ABSA)

La clasificación a nivel de documento es demasiado gruesa para muchas aplicaciones. El ABSA identifica el sentimiento hacia aspectos específicos: "La cámara es excelente pero la batería es pesada." Las reseñas de IMDb pueden contener opiniones combinadas sobre el guion, la actuación y la dirección, que una etiqueta binaria única no puede representar. Los modelos ABSA modernos utilizan mecanismos de atención para anclar el sentimiento a entidades.

Sesgo y desequilibrio de clases

En datos reales los sentimientos suelen estar desequilibrados. Los modelos entrenados en datasets balanceados como IMDb pueden tener bajo rendimiento en producción. La métrica de exactitud oculta este problema: un clasificador que predice siempre "positivo" en un dataset 80/20 obtiene 80% de exactitud pero 0% de recall para la clase negativa. Las métricas macro-F1 y la matriz de confusión son herramientas más informativas en estos escenarios.

Deriva temporal del lenguaje (temporal drift)

El slang, las expresiones emergentes y el significado de palabras evolucionan con el tiempo. Un modelo entrenado en reseñas de 2010 puede no capturar la semántica actual de redes sociales, lo que requiere reentrenamiento periódico o mecanismos de actualización incremental. Este reto es especialmente crítico en plataformas de monitoreo de opinión pública en tiempo real.

1.4 Reflexión sobre el papel de los datos

La centralidad de los datos

El análisis de sentimientos, como cualquier tarea de aprendizaje supervisado, está determinado fundamentalmente por la calidad y las características de los datos. Los datos no son un insumo pasivo: condicionan qué puede aprender el modelo, qué errores cometerá y a qué subpoblaciones generalizará. Las dimensiones críticas son: calidad de anotación, balance de clases, preprocesamiento y representatividad demográfica y cultural.

Calidad vs. cantidad y anotación

Un dataset de 5 000 reseñas bien anotadas puede superar a uno de 50 000 con etiquetas ruidosas. En IMDb, la calidad es alta porque las etiquetas provienen implícitamente del rating

numerico del usuario (escala 1-10). Cuando los datos se etiquetan manualmente, la subjetividad genera discrepancias entre anotadores. El indice Kappa de Cohen mide este acuerdo; valores inferiores a 0.7 indican que la tarea ya es ambigua a nivel humano, lo cual establece un techo para el rendimiento de cualquier modelo automatico.

Preprocesamiento como transformacion de los datos

Cada decision de preprocesamiento modifica la representacion que el modelo aprende. Incluir bigramas (`ngram_range=(1,2)`) captura expresiones de negacion como "not good" que los unigramas perderian. Eliminar stopwords reduce el ruido pero puede borrar marcadores de negacion criticos como "not" o "never". Aplicar lematizacion normaliza variantes morfologicas. Estas decisiones deben tomarse con conocimiento del dominio y validarse empiricamente.

Sesgo de seleccion y el dato como artefacto social

IMDb esta sesgado hacia usuarios angloparlantes que escriben resenas largas, excluyendo opiniones en otros idiomas y perspectivas culturales diversas. Los textos de opinion no son datos neutros: reflejan culturas y perspectivas de sus autores. Un analizador entrenado en IMDb puede comportarse de forma diferente ante textos de personas de distintos contextos culturales, con implicaciones eticas relevantes en aplicaciones de analisis politico o de opinion publica a gran escala.

PARTE II: TUTORIAL HUGGINGFACE + ARGILLA

2.1 Descripcion del flujo de trabajo

Contexto

HuggingFace proporciona el dataset IMDb como benchmark estandar en su libreria datasets. El tutorial propone un flujo de trabajo que combina inferencia zero-shot y fine-tuning con revision asistida por humanos mediante la plataforma Argilla. Este enfoque reduce drasticamente el esfuerzo de anotacion manual al aprovechar la capacidad de generalizacion de los Transformers preentrenados.

Etapas del pipeline

El flujo completo consta de cinco etapas interconectadas:

- Carga del dataset: `datasets.load_dataset("imdb")` descarga el corpus desde el HuggingFace Hub con splits de entrenamiento y prueba ya definidos.
- Inferencia zero-shot con `distilbert-base-uncased-finetuned-sst-2-english` para obtener predicciones iniciales sin entrenamiento adicional sobre el dominio objetivo.
- Envio a Argilla: las predicciones de baja confianza (probabilidad por debajo de un umbral configurable) se registran en la interfaz web de Argilla para revision y correccion manual por el anotador humano.
- Fine-tuning supervisado: con las anotaciones corregidas se lanza un ciclo de ajuste fino usando la API Trainer de HuggingFace Transformers, actualizando los pesos del modelo base.
- Evaluacion y despliegue: el modelo ajustado se evalua sobre el conjunto de prueba y puede publicarse en el HuggingFace Hub para reutilizacion y reproducibilidad.

2.2 Fortalezas y limitaciones del flujo de trabajo

Fortalezas

- Reduccion del esfuerzo de anotacion: la inferencia zero-shot genera etiquetas candidatas automaticamente; el humano solo revisa los casos dudosos (baja confianza), reduciendo el trabajo de anotacion en mas de un 70%.
- Iteracion progresiva (active learning): el ciclo inferir-revisar-ajustar mejora el modelo con cada ronda de anotacion, convergiendo hacia un modelo robusto con pocos recursos humanos.
- Trazabilidad y auditoria: Argilla registra el historial completo de anotaciones, desacuerdos y correcciones, facilitando la gobernanza de datos y la reproducibilidad del experimento.
- Ecosistema integrado: HuggingFace Hub, transformers, datasets y Argilla estan disenados para trabajar juntos, minimizando la friccion de integracion tecnica.

Limitaciones

- Dependencia de hardware especializado: el fine-tuning de Transformers requiere GPU (recomendable ≥ 8 GB VRAM). En entornos sin GPU el proceso puede ser inviable de forma local.
- Coste de la inferencia a escala: aunque no requiere entrenamiento, la inferencia con modelos grandes puede ser lenta para datasets de millones de registros.
- Complejidad de infraestructura: configurar Argilla (servidor Docker, autenticacion, interfaz web) nade complejidad respecto a un pipeline simple de scikit-learn.
- Rendimiento con pocos datos anotados: si el corpus revisado es pequeno (< 500 ejemplos), el fine-tuning puede no mejorar significativamente sobre el modelo base sin ajuste.

2.3 Adaptaciones propuestas

Para modelos no profundos (ML clasico)

Para implementar un flujo conceptualmente equivalente usando clasificadores clasicos (SVM, KNN, Naive Bayes), se propone reemplazar cada componente del pipeline Transformer por una contraparte ligera:

- Estandar Transformer --> Equivalente clasico
- Inferencia zero-shot --> SVM o NB entrenado con pocos ejemplos etiquetados manualmente como semilla inicial.
- Confianza del modelo --> Distancia al hiperplano de decision del SVM; los ejemplos con distancia cercana a 0 son los mas inciertos y mejores candidatos para revision humana.
- Fine-tuning (Trainer API) --> Reentrenamiento incremental con scikit-learn anadiendo los ejemplos revisados al conjunto de entrenamiento.

Este enfoque no requiere GPU ni infraestructura de servidor, tiene ciclos de entrenamiento en segundos o minutos, y ofrece alta interpretabilidad: los coeficientes del SVM lineal permiten identificar directamente que palabras pesan mas en la decision positiva o negativa.

Adaptaciones para datos en espanol

Para adaptar el analizador al espanol se requieren cambios especificos en cada etapa del pipeline de procesamiento:

- Dataset: Corpus TASS (tweets en espanol con anotacion de sentimiento), MR-TASS (resenas de cine en espanol), XNLI en espanol (version multilingue de SST-2 traducida y validada).

- Stopwords: reemplazar stop_words="english" por una lista en español en TfidfVectorizer (disponible en NLTK y spaCy con el modelo es_core_news_sm).
- Preprocesamiento lingüístico: lematización con spaCy en lugar de stemming; el español tiene mayor riqueza morfológica que el inglés (conjugaciones, géneros, plurales).
- Lexicos de sentimiento: ML-SentiCon (cobertura amplia), iSol (Universidad Politécnica de Valencia) y AFINN-165 traducido al español.
- Modelos Transformer para español: BETO (dccuchile/bert-base-spanish-wwm-cased), RoBERTa-BNE (PlanTL-GOB-ES/roberta-base-bne), pysentimiento/robertuito-sentiment-analysis (ya ajustado para Twitter en español).

PARTE III: IMPLEMENTACION PRACTICA CON ML CLASICO

La Parte III implementa tres clasificadores de Machine Learning clásico sobre el corpus completo de 50 000 reseñas de IMDb, demostrando que los métodos no profundos son competitivos cuando el hardware es limitado. Esta sección resume la metodología y los resultados obtenidos.

3.1 Configuración experimental

El pipeline experimental sigue una metodología reproducible y sistemática:

- Preprocesamiento: codificación de etiquetas binarias (0=negativo, 1=positivo), muestra aleatoria de 5 000 registros para agilizar el desarrollo, división train/test (80% / 20%).
- Vectorización TF-IDF con bigramas (ngram_range=(1,2)), limitada a 50 000 características; eliminación de stopwords en inglés.
- Entrenamiento de tres clasificadores: SVM con kernel lineal (LinearSVC), KNN con k=5 y distancia euclidiana, Naive Bayes multinomial.
- Evaluación con cuatro métricas: exactitud, precisión macro, recall macro y F1-Score macro, más matriz de confusión por modelo.
- Tabla comparativa y gráfico de barras de las métricas de los tres modelos.
- Predictor personalizado para nuevas reseñas usando el modelo de mayor F1-Score.

3.2 Resultados y hallazgos principales

Los experimentos confirman las predicciones teóricas de la literatura. SVM alcanza el mayor F1-Score, seguido de Naive Bayes y finalmente KNN, en consonancia con Keerthi et al. (2018). La vectorización con bigramas es clave para capturar expresiones de negación como "not good" que los unigramas perderían, impactando directamente en la precisión del análisis. El muestreo a 5 000 registros es un compromiso aceptable; usar el dataset completo mejoraría los modelos basados en estadística de corpus pero con tiempos de entrenamiento significativamente mayores.

CONCLUSIONES

4.1 Sobre los modelos

- SVM es el mejor clasificador en este contexto: kernel lineal con TF-IDF y bigramas alcanza el mayor F1-Score, resultado consistente con la literatura (Keerthi et al., 2018).
- Naive Bayes ofrece una excelente relacion rendimiento/velocidad; sus metricas son competitivas con entrenamiento en apenas segundos, lo que lo hace preferible en escenarios de prototipado rapido.
- KNN es el modelo mas debil para esta representacion: la maldicion de la dimensionalidad afecta especialmente a los vectores TF-IDF de alta dispersion.
- La vectorizacion con bigramas es determinante para capturar la negacion en el lenguaje natural.

4.2 Sobre los datos y el proceso

- El equilibrio de clases en IMDb facilita la evaluacion con exactitud. En produccion con datos desbalanceados, el F1 por clase y la matriz de confusion son mas informativos.
- El muestreo a 5 000 registros es representativo para comparar modelos; el dataset completo mejoraria los resultados absolutos.
- La expansion al espanol requiere adaptaciones en stopwords, lematizacion, lexicos y modelos; BETO y RoBERTa-BNE son puntos de partida solidos.

4.3 Sobre el analisis de sentimientos en general

Los clasificadores clasicos son una alternativa viable cuando el hardware es limitado. Aunque los Transformers (BERT, DistilBERT) superan a SVM/NB en benchmarks, la brecha es menor de lo esperado en datasets de longitud media como IMDb. La eleccion del clasificador debe equilibrar rendimiento, interpretabilidad, latencia y recursos disponibles. El flujo HuggingFace + Argilla representa el estandar de la industria para la construccion iterativa de datasets anotados de alta calidad, aplicable tanto a Transformers como a enfoques clasicos con las adaptaciones propuestas en este trabajo.

REFERENCIAS

- [1] Maas, A. L., Daly, R. E., Pham, P. T., Huang, D., Ng, A. Y., & Potts, C. (2011). Learning word vectors for sentiment analysis. In Proceedings of the 49th Annual Meeting of the ACL (pp. 142-150). Association for Computational Linguistics.
- [2] Keerthi, C., Harish, B. S., & Darshan, H. S. (2018). Sentiment Analysis on IMDb Movie Reviews Using Hybrid Feature Extraction Method. International Journal of Interactive Multimedia and Artificial Intelligence, 5(1), 109-114.
- [3] Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A. Y., & Potts, C. (2013). Recursive deep models for semantic compositionality over a sentiment treebank. Proceedings of EMNLP, 1631-1642.
- [4] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT 2019, 4171-4186.
- [5] Canete, J., Chaperon, G., Fuentes, R., Ho, J. H., Kang, H., & Perez, J. (2020). Spanish pre-trained BERT model and evaluation data (BETO). PML4DC at ICLR 2020.

- [6] HuggingFace. (2024). Datasets library documentation. <https://huggingface.co/docs/datasets/>
- [7] Argilla. (2024). Argilla: Open-source data annotation platform for NLP. <https://argilla.io/>
- [8] Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., & Bowman, S. R. (2018). GLUE: A multi-task benchmark and analysis platform for natural language understanding. Proceedings of ICLR 2019.
- [9] Pontiki, M., Galanis, D., Papageorgiou, H., Androutsopoulos, I., & Manandhar, S. (2016). SemEval-2016 task 5: Aspect based sentiment analysis. Proceedings of SemEval, 19-30.
- [10] Perez, J. M., Giudici, J. C., & Luque, F. (2021). pysentimiento: A Python toolkit for opinion mining and social NLP tasks. arXiv:2106.09462.