

Analizador de Sentimientos — Dataset IMDb

Universidad Internacional de La Rioja (UNIR)

Máster en Inteligencia Artificial

Asignatura: Procesamiento del Lenguaje Natural

Campo	Detalle
Alumno	Omar Joel Montemayor Charles
Actividad	Actividad 2 — Análisis de Sentimientos
Fecha	13 de Abril de 2026

Este notebook cubre los requisitos de la Actividad 2 en tres partes:

- **Parte I — Marco Teórico:** preguntas preliminares sobre fundamentos, casos de uso, retos abiertos y el papel de los datos.
- **Parte II — Tutorial HuggingFace + Argilla:** descripción del flujo de trabajo y adaptaciones propuestas.
- **Parte III — Implementación Práctica:** clasificadores clásicos de ML (SVM, KNN, Naive Bayes) sobre el dataset IMDb de 50 000 reseñas.

PARTE I: Marco Teórico e Investigación

Pregunta 1 — Definición de análisis de sentimientos y particularidades en IMDb y SST-2

¿Qué es el análisis de sentimientos?

El **análisis de sentimientos** (también llamado *minería de opiniones*) es una subdisciplina del Procesamiento del Lenguaje Natural (PLN) cuyo objetivo es identificar, extraer y cuantificar la información subjetiva presente en textos escritos. A nivel práctico, implica determinar la **polaridad** o **actitud** del autor respecto a un tema, producto, entidad o evento —normalmente clasificando el texto como *positivo*, *negativo* o *neutro*, aunque existen variantes con escalas de intensidad o categorías de emoción más finas.

A diferencia del análisis de contenido objetivo (extracción de hechos), el análisis de sentimientos trabaja con lenguaje inherentemente subjetivo: opiniones, juicios de valor, expresiones coloquiales, ironías y referentes culturales, lo que lo convierte en uno de los problemas más desafiantes del PLN.

Particularidades del dataset IMDb

El dataset de IMDb consiste en **50 000 reseñas de películas** con etiquetado binario (positivo / negativo), derivado del rating numérico otorgado por el propio usuario (1–4 → negativo, 7–10 → positivo, excluidos los valores intermedios). Sus particularidades principales son:

- **Texto largo:** promedio aproximado de 230 palabras por reseña, lo que aporta contexto rico pero también ruido léxico y mayor coste computacional.
- **Vocabulario cinematográfico específico:** actores, directores, géneros, narrativa. Los modelos entrenados aquí pueden no generalizar bien a otros dominios.
- **Balance perfecto de clases:** 25 000 positivos / 25 000 negativos, lo que facilita la evaluación con métricas de exactitud.
- **Lenguaje subjetivo complejo:** abundan metáforas, sarcasmo sutil y referencias culturales difíciles de capturar con métodos no profundos.
- **Benchmark estándar en la literatura:** desde el trabajo seminal de Maas et al. (2011), IMDb es el dataset de referencia para comparar clasificadores de sentimiento.

Particularidades del dataset SST-2

SST-2 (*Stanford Sentiment Treebank*, versión binaria, incluido en el benchmark GLUE) proviene de reseñas de **Rotten Tomatoes** y presenta características distintas:

- **Oraciones cortas:** promedio aproximado de 19 palabras. Las instancias son frases extraídas de reseñas, no reseñas completas.
- **Anotación en árbol sintáctico:** la versión completa SST proporciona etiquetas de sentimiento a nivel de frase y sub-frase, permitiendo estudiar la composicionalidad del sentimiento.
- **Versión binaria (SST-2):** se eliminan las instancias neutras, haciendo la tarea directamente comparable con IMDb.
- **Benchmark de facto para Transformers:** SST-2 fue la tarea de clasificación de referencia en los primeros papers de BERT y sigue siendo estándar para comparar modelos de lenguaje preentrenados.

Comparativa IMDb vs. SST-2

Característica	IMDb	SST-2
Fuente	Reseñas completas de IMDb	Frases de Rotten Tomatoes
Longitud media	~230 palabras	~19 palabras
Etiquetas	Positivo / Negativo	Positivo / Negativo
Tamaño	50 000	~67 000 frases
Anotación	Automática (rating numérico)	Humana (árbol sintáctico)
Uso típico	Clasificación de texto largo	Fine-tuning y benchmarking

Pregunta 2 — Caso de uso concreto: Keerthi, Harish y Darshan (2018)

Referencia: Keerthi, A., Harish, B. S. y Darshan, H. N. (2018). *Sentiment Analysis on IMDb Movie Reviews Using Hybrid Feature Extraction Method*. *International Journal of Interactive Multimedia and Artificial Intelligence*, 5(1), 47–55.

Descripción del problema

Los autores identifican que los métodos de extracción de características aisladas (solo TF-IDF o solo características semánticas) presentan limitaciones para capturar la riqueza léxica y semántica de las reseñas de IMDb. Proponen un **método híbrido** que combina múltiples representaciones complementarias antes de aplicar los clasificadores.

Arquitecturas y pipeline propuesto

1. Preprocesamiento: - Eliminación de etiquetas HTML (las reseñas de IMDb contienen marcado HTML residual). - Tokenización, conversión a minúsculas y eliminación de signos de puntuación. - Eliminación de *stopwords* (palabras vacías de significado semántico). - *Stemming* con Porter Stemmer para reducir variantes morfológicas a la raíz.

2. Extracción de características (método híbrido): - **TF-IDF:** captura la importancia estadística de los términos en el corpus. - **Características estadísticas:** frecuencia de bigramas, longitud de la reseña, densidad léxica. - **Características semánticas:** puntuaciones de positividad y negatividad de los tokens mediante **SentiWordNet**.

Los tres vectores se concatenan formando una representación híbrida única.

3. Clasificadores evaluados: Naive Bayes, SVM (kernel lineal), Logistic Regression y KNN.

Resultados obtenidos

Modelo	Solo TF-IDF (Acc.)	Método Híbrido (Acc.)	Mejora
Naive Bayes	83.1 %	85.4 %	+2.3 pp
SVM	87.6 %	89.2 %	+1.6 pp
Logistic Regression	86.3 %	88.1 %	+1.8 pp
KNN	79.8 %	82.3 %	+2.5 pp

El **SVM con método híbrido** obtuvo el mejor resultado (89.2 % de exactitud en un subconjunto de 25 000 reseñas de IMDb).

Conclusiones del artículo

- La combinación de representaciones estadísticas y semánticas mejora consistentemente la exactitud respecto al TF-IDF aislado en todos los clasificadores evaluados.
- El SVM lineal se revela como el clasificador más robusto para este dominio, gracias a su capacidad de separación óptima en espacios de alta dimensionalidad.
- La incorporación de léxicos de sentimiento (SentiWordNet) aporta información que los vectores de frecuencia no pueden capturar, especialmente para palabras de polaridad fuerte.
- KNN muestra el peor rendimiento relativo, probablemente por la maldición de la dimensionalidad inherente a vectores TF-IDF dispersos en miles de dimensiones.

Pregunta 3 — Retos abiertos en el análisis de sentimientos

A partir de Keerthi et al. (2018) y de la literatura reciente, se identifican los siguientes retos abiertos:

1. Detección de sarcasmo e ironía

El sarcasmo expresa un sentimiento opuesto al significado literal: *"Brillante guión, digno de un Oscar"* puede ser un insulto. Los modelos clásicos basados en bolsa de palabras o TF-IDF son especialmente vulnerables porque no modelan el contexto global ni el tono. Es probablemente el error más frecuente en clasificadores binarios de reseñas de cine.

2. Dependencia del dominio (*domain adaptation*)

Un modelo entrenado en IMDb puede no generalizar a productos electrónicos o noticias financieras, donde las mismas palabras tienen connotaciones diferentes. La mayoría de los sistemas comerciales necesitan adaptarse a dominios dinámicos sin grandes colecciones de datos anotados.

3. Idiomas de bajos recursos (*low-resource languages*)

La gran mayoría de los datasets etiquetados están en inglés. Para lenguas con pocos recursos (quechua, idiomas africanos, lenguas regionales), los modelos preentrenados y los métodos clásicos tienen un rendimiento muy inferior.

4. Análisis de sentimiento a nivel de aspecto (ABSA)

La clasificación a nivel de documento es demasiado gruesa para muchas aplicaciones. El ABSA (*Aspect-Based Sentiment Analysis*) identifica el sentimiento hacia aspectos específicos: "La cámara es excelente pero la batería es pésima" → positivo:cámara / negativo:batería. Es fundamental para análisis de productos y encuestas de satisfacción.

5. Sesgo y desequilibrio de clases

En datos reales los sentimientos suelen estar desequilibrados. Los modelos entrenados en datasets balanceados como IMDb pueden tener bajo rendimiento en producción. La métrica de exactitud oculta este problema; de ahí la importancia del F1-Score y el análisis por clase.

6. Deriva temporal del lenguaje (*temporal drift*)

El slang, las expresiones emergentes y el significado de palabras evolucionan con el tiempo. Un modelo entrenado en reseñas de 2010 puede no capturar la semántica actual de redes sociales, lo que requiere estrategias de actualización continua (*continual learning*) con el consiguiente coste operativo.

| Pregunta 4 — Reflexión sobre el papel de los datos

La centralidad de los datos en el análisis de sentimientos

El análisis de sentimientos, como cualquier tarea de aprendizaje supervisado, está determinado fundamentalmente por la calidad y las características de los datos. Los datos no son un insumo pasivo: condicionan el comportamiento del modelo, las métricas que se pueden obtener y los sesgos que se propagan.

1. Calidad vs. cantidad

Un dataset de 5 000 reseñas bien anotadas puede superar a uno de 50 000 con etiquetas ruidosas. En IMDb, la calidad es alta porque las etiquetas provienen implícitamente del rating numérico del usuario, mitigando la ambigüedad de la anotación manual. Sin embargo, casos extremos como ironías o textos ambiguos permanecen incorrectamente etiquetados, limitando el techo de rendimiento del modelo.

2. Anotación y acuerdo entre anotadores

Cuando los datos se etiquetan manualmente, la subjetividad del sentimiento hace que distintos anotadores discrepen. El índice Kappa de Cohen mide este acuerdo; valores bajos (<0.7) indican que la tarea es ambigua. En dominios sin señal implícita (redes sociales neutras) la anotación manual introduce ruido significativo que arrastra el rendimiento.

3. Balance de clases e implicaciones en las métricas

IMDb está perfectamente balanceado (50/50), lo que favorece la evaluación con exactitud. En datos reales con desequilibrio (p. ej., 80 % positivo en plataformas de e-commerce), la exactitud puede ser engañosamente alta. Métricas como F1-Score, precisión y recall por clase son más informativas en estos escenarios.

4. Preprocesamiento como transformación de los datos

Cada decisión de preprocesamiento modifica la representación que el modelo aprende. Incluir bigramas (`ngram_range=(1, 2)`) captura expresiones de negación como *"not good"* que los unigramas perderían. Estas decisiones del pipeline son parte del diseño de los datos.

5. Sesgo de selección y representatividad

IMDb está sesgado hacia usuarios angloparlantes que escriben reseñas largas. Excluye personas que no escriben reseñas, opiniones en otros idiomas y perspectivas culturales diversas. Cualquier conclusión del modelo debe considerarse circunscrita a este perfil.

6. El dato como artefacto social

Los textos de opinión no son datos neutros: reflejan culturas y perspectivas de sus autores. Un analizador entrenado en IMDb puede comportarse de forma diferente ante textos de personas de distintos contextos culturales, planteando preguntas éticas sobre su uso en sistemas de toma de decisiones automatizadas.

PARTE II: Tutorial HuggingFace + Argilla

5. Descripción del proceso del tutorial

Contexto

HuggingFace proporciona el dataset IMDb como benchmark estándar en su librería `datasets`. El tutorial propone un flujo de trabajo que combina inferencia zero-shot y fine-tuning con revisión asistida por Argilla:

1. **Carga del dataset** desde el hub: `datasets.load_dataset("imdb")`.
2. **Inferencia zero-shot** con un modelo preentrenado (`distilbert-base-uncased-finetuned-sst-2-english`) para obtener predicciones iniciales sin entrenamiento adicional.
3. **Envío a Argilla**: las predicciones de baja confianza se registran en la interfaz web de Argilla para revisión y corrección manual.
4. **Fine-tuning supervisado**: con las anotaciones corregidas se lanza un ciclo de ajuste fino usando la API `Trainer` de HuggingFace Transformers.
5. **Evaluación y despliegue**: el modelo ajustado se evalúa sobre el conjunto de prueba y puede publicarse en el HuggingFace Hub.

Pasos para obtener un analizador entrenado

Paso	Acción	Herramienta
1	Instalar dependencias	<code>pip install transformers datasets argilla</code>
2	Cargar el dataset IMDb	<code>datasets.load_dataset("imdb")</code>
3	Cargar pipeline zero-shot	<code>pipeline("text-classification", model="distilbert-base-uncased-finetuned-sst-2-english")</code>
4	Ejecutar inferencia sobre el conjunto de prueba	<code>pipeline(batch_of_texts)</code>
5	Registrar resultados de baja confianza en Argilla	<code>rg.log(records, dataset="imdb-review")</code>
6	Revisar y corregir etiquetas en la UI de Argilla	Interfaz web (localhost:6900)
7	Exportar datos anotados	<code>rg.load("imdb-review")</code>

8	Fine-tuning con Trainer	<code>Trainer(model, training_args, train_dataset, ...).train()</code>
9	Evaluar el modelo ajustado	<code>Trainer.evaluate()</code>
10	Publicar en HuggingFace Hub (opcional)	<code>model.push_to_hub("mi-modelo-imdb")</code>

6. Valoración de la utilidad del flujo de trabajo

Fortalezas

- **Reducción del esfuerzo de anotación:** la inferencia zero-shot genera etiquetas candidatas automáticamente. El anotador humano solo revisa los casos dudosos (baja confianza), reduciendo el trabajo de anotación en un 60–80 % respecto a etiquetar desde cero.
- **Iteración progresiva (*active learning*):** el ciclo *inferir* → *revisar* → *ajustar* mejora el modelo con cada ronda de anotación, convergiendo hacia un modelo robusto con pocos recursos humanos.
- **Trazabilidad y auditoría:** Argilla registra el historial completo de anotaciones, desacuerdos y correcciones, facilitando la gobernanza de datos y la reproducibilidad.
- **Ecosistema integrado:** HuggingFace Hub, transformers, datasets y Argilla están diseñados para trabajar juntos, minimizando la fricción de integración.

Limitaciones

- **Dependencia de hardware especializado:** el fine-tuning de Transformers requiere GPU (recomendable ≥ 8 GB VRAM). En entornos sin GPU, el proceso puede ser inviable localmente.
- **Coste de la inferencia a escala:** aunque no requiere entrenamiento, la inferencia con modelos grandes puede ser lenta para datasets de millones de registros.
- **Complejidad de infraestructura:** configurar Argilla (servidor Docker, autenticación, interfaz web) añade complejidad respecto a un pipeline simple de scikit-learn.
- **Rendimiento con pocos datos anotados:** si el corpus revisado es pequeño (<500 ejemplos), el fine-tuning puede no mejorar significativamente sobre el modelo base.

7. Adaptaciones para modelos no profundos

Para implementar un flujo conceptualmente equivalente usando **clasificadores clásicos de Machine Learning** (SVM, KNN, Naive Bayes), se proponen las siguientes adaptaciones:

Equivalencia conceptual

Paso del tutorial (Transformers)	Equivalente con ML clásico
Modelo preentrenado (zero-shot)	Léxico de sentimiento (VADER, SentiWordNet) como clasificador inicial de bajo coste
Inferencia → Argilla (revisión)	Exportar a CSV las predicciones de alta incertidumbre (baja distancia al hiperplano en SVM, baja probabilidad de clase en NB) para revisión manual
Fine-tuning con <code>Trainer</code>	Re-entrenamiento de <code>model.fit()</code> con los nuevos ejemplos revisados añadidos al conjunto de entrenamiento
Publicar en Hub	Serializar con <code>joblib.dump()</code> y versionar con Git/DVC

Estrategia de selección de ejemplos inciertos para revisión manual

Con **SVM lineal**, la función de decisión devuelve una distancia al hiperplano. Los ejemplos más cercanos a 0 son los más inciertos y los mejores candidatos para revisión humana:

```
scores = svm_model.decision_function(X_pool_tfidf)
indices_inciertos = np.argsort(np.abs(scores))[:200] # Los 200 más inciertos
df_revision = df_pool.iloc[indices_inciertos][['review', 'sentiment']]
df_revision.to_csv('revision_manual.csv', index=False)
```

Con **Naive Bayes**, se puede usar la probabilidad máxima predicha como proxy de confianza:

```
probas = nb_model.predict_proba(X_pool_tfidf).max(axis=1)
indices_inciertos = np.argsort(probas)[:200] # Menor confianza
```

Ventajas de este enfoque

- No requiere GPU ni infraestructura de servidor.

- Ciclos de entrenamiento en segundos o minutos.
- Interpretabilidad: SVM lineal permite identificar qué palabras pesan más en la decisión a través de los coeficientes del hiperplano.

8. Adaptaciones para trabajar con datos en español

Para adaptar el analizador de sentimientos al español, se requieren cambios en cada etapa del pipeline:

1. Dataset

- **Corpus TASS** (*Twitter Analysis Shared Task*): corpus en español de tweets con anotación de sentimiento, utilizado en competiciones anuales de PLN en español.
- **MR-TASS y Spanish Movie Reviews**: datasets de reseñas de cine en español disponibles en repositorios académicos.
- **XNLI en español**: versión multilingüe de SST-2 traducida y validada.

2. Stopwords

Reemplazar `stop_words='english'` en `TfidfVectorizer` por una lista en español:

```
from nltk.corpus import stopwords
sw_es = stopwords.words('spanish')
vectorizer = TfidfVectorizer(max_features=5000, stop_words=sw_es, ngram_range=(1, 2))
```

3. Preprocesamiento lingüístico

El español tiene mayor riqueza morfológica que el inglés (conjugaciones, géneros, plurales). Se recomienda: - **Lematización** con `spacy` (modelo `es_core_news_sm`) en lugar de stemming, preservando el significado de la raíz. - **Manejo de caracteres especiales**: tildes (á, é, í, ó, ú) y la ñ son informativos; no eliminarlos. Asegurar `encoding='utf-8'` en la lectura.

4. Léxicos de sentimiento en español

- **ML-SentiCon**: léxico de sentimiento específico para el español con cobertura amplia.
- **iSol**: léxico de polaridad desarrollado por la Universidad Politécnica de Valencia.
- **AFINN-165 (traducido)**: versión traducida al español del léxico AFINN.

5. Modelos Transformer para español (si se dispone de GPU)

- `dccuchile/bert-base-spanish-wwm-cased` (BETO): BERT entrenado en un corpus masivo de español.
- `PlanTL-GOB-ES/roberta-base-bne`: RoBERTa entrenado sobre el corpus del Plan de Tecnología del Lenguaje de España.
- `pysentimiento/robertuito-sentiment-analysis`: modelo ya ajustado para análisis de sentimientos en español (ideal para Twitter y redes sociales).

PARTE III: Implementación Práctica con Machine Learning Clásico

Se implementan tres clasificadores sobre el dataset de **50 000 reseñas de IMDb**:

1. **Preprocesamiento**: codificación de etiquetas, muestra de 5 000 registros, división train/test (80/20), vectorización TF-IDF con bigramas.
2. **Entrenamiento y evaluación** de SVM, KNN y Naive Bayes con 4 métricas: exactitud, precisión, recall y F1-Score, más matriz de confusión.
3. **Comparación** de modelos con tabla resumen y gráficos.
4. **Predictor personalizado** para nuevas reseñas con el mejor modelo.

CONCLUSIONES

Sobre los modelos implementados

A partir de los resultados obtenidos con una muestra de 5 000 reseñas del dataset IMDb, se extraen las siguientes conclusiones:

SVM es el mejor clasificador en este contexto. El kernel lineal con TF-IDF y bigramas alcanza el mayor F1-Score, consistentemente superior al de KNN y Naive Bayes. Este resultado está en línea con los hallazgos de Keerthi et al. (2018), donde SVM también lideró la comparativa con el método híbrido.

Naive Bayes ofrece una excelente relación rendimiento/velocidad. A pesar de su supuesto de independencia, alcanza métricas competitivas con un entrenamiento de apenas segundos, lo que lo hace preferible cuando los recursos computacionales son limitados o se necesita actualización frecuente del modelo.

KNN es el modelo más débil para esta representación. La maldición de la dimensionalidad afecta de forma especialmente intensa a los vectores TF-IDF de alta dispersión, lo que confirma los resultados de la literatura.

La vectorización con bigramas es clave. El parámetro `ngram_range=(1, 2)` captura expresiones de negación como *"not good"* o *"no way"* que los unigramas perderían, impactando directamente en la precisión del análisis.

Sobre los datos y el proceso

El equilibrio de clases en IMDb facilita la evaluación con métricas de exactitud. En producción con datos desbalanceados, el F1-Score por clase y la matriz de confusión serían más informativos.

El muestreo a 5 000 registros es un compromiso aceptable. Permite ciclos de desarrollo rápidos con resultados representativos. Usar el dataset completo (50 000 reseñas) mejoraría los modelos basados en frecuencias pero incrementaría significativamente el tiempo de entrenamiento del SVM.

Sobre el análisis de sentimientos en general

Los clasificadores clásicos son una alternativa viable cuando el hardware es limitado. Aunque los Transformers (BERT, DistilBERT) superan a SVM/NB en benchmarks, la brecha es menor de lo esperado para clasificación binaria sobre texto en inglés con vocabulario controlado.

La expansión al español requiere adaptaciones específicas: stopwords, lematización, léxicos de sentimiento y datasets de dominio. Modelos como BETO o RoBERTa-BNE ofrecen un punto de partida sólido para el español con enfoque Transformer.